



Universidad Internacional de La Rioja
Escuela Superior de Ingeniería y Tecnología

Maestría en Inteligencia Artificial
**Sistema Inteligente de Reportes de
Emergencia Ciudadana (SIREC):
clasificación y priorización automática de
reportes ciudadanos de emergencia
mediante procesamiento del lenguaje
natural**

Trabajo de innovación presentado por:	Alexis Salvador Herrera García Edy Nahum De León Gálvez Ricardo Gurrola Palacios
Fecha:	Veracruz, México, agosto de 2026

Índice de contenidos

Actualice el índice con clic derecho › Actualizar campos (F9).

1. INTRODUCCIÓN

Este primer capítulo presenta el trabajo al lector y delimita el terreno sobre el que se construye la propuesta de innovación. Comienza con el contexto de las emergencias de origen natural en México y, en particular, en el estado de Veracruz; continúa con el planteamiento del problema concreto que se aborda —el triaje manual de los reportes ciudadanos— y con su justificación a partir de datos oficiales; y cierra con la delimitación del alcance y con la explicación de cómo se organiza el resto del documento.

1.1 CONTEXTO Y MOTIVACIÓN

México es un país expuesto de forma recurrente a fenómenos de origen natural cuyo impacto social y económico se documenta cada año. Según el Centro Nacional de Prevención de Desastres, durante 2023 los desastres ocurridos en el país dejaron daños y pérdidas por 88 910 millones de pesos, equivalentes a 0.3 % del producto interno bruto, y 984 defunciones confirmadas; de esos daños, 98.1 % correspondió a fenómenos hidrometeorológicos, a los que se asoció también el 52.2 % de las defunciones (Cenapred, 2024).

Veracruz ocupa un lugar destacado en ese panorama. En 2023 concentró 7.0 % de las defunciones causadas por fenómenos de origen natural y fue escenario de dos de los seis eventos hidrometeorológicos más costosos del año: la lluvia severa con inundación fluvial y pluvial de octubre y la tormenta tropical Max de agosto (Cenapred, 2024). La recurrencia no es excepcional, pues el análisis de las declaratorias de desastre registradas entre 2003 y 2022 muestra que las afectaciones hidrometeorológicas son un fenómeno sostenido en el territorio veracruzano (Valdés-Rodríguez, 2025).

Cuando una contingencia ocurre, la ciudadanía acude al canal institucional de emergencia y las coordinaciones municipales de protección civil se convierten en el primer punto de contacto con la respuesta del Estado. El volumen de ese canal es considerable: entre enero y junio de 2026 los Centros de Atención de Llamadas de Emergencia registraron 27 204 813 llamadas al número único 9-1-1, de las cuales 7 620 591 se canalizaron a alguna corporación por relacionarse con hechos que ponen en riesgo a las personas; Veracruz aportó 1 475 239 y se ubicó en el sexto lugar nacional (Centro Nacional de Información, 2026).

Esas cifras describen también la dificultad de fondo. El 72.0 % de las llamadas recibidas en el país resultó improcedente —llamadas mudas, incompletas, bromas o asuntos ajenos a una

emergencia—, proporción que en Veracruz asciende a 77.3 % (Centro Nacional de Información, 2026).

A esa carga se añade la granularidad de la clasificación. El Catálogo Nacional de Incidentes de Emergencia comprende siete tipos de incidente, 24 subtipos y 282 incidentes específicos (Centro Nacional de Información, 2025), y en el primer semestre de 2026 se registraron llamadas en 206 de ellos. Quien atiende un reporte no resuelve una decisión binaria, sino una clasificación de grano fino tomada en segundos, y de ahí que el triaje sea un punto crítico de la cadena de respuesta. La tabla 1 resume estas magnitudes.

Tabla 1. Llamadas de emergencia al número único 9-1-1 en México y en Veracruz, enero-junio de 2026.

Indicador	Nacional	Veracruz
Llamadas registradas	27 204 813	1 475 239
Llamadas procedentes (canalizadas a una corporación)	7 620 591 (28.0 %)	334 843 (22.7 %)
Llamadas improcedentes	19 584 222 (72.0 %)	1 140 396 (77.3 %)

Fuente: Elaboración propia con datos abiertos del Centro Nacional de Información (2026).

1.2 PLANTEAMIENTO DEL PROBLEMA

El problema que motiva este trabajo es que el triaje de los reportes ciudadanos de emergencia se realiza de forma manual y sin un criterio de urgencia documentado, justo en el momento en que cada minuto cuenta. Los reportes llegan redactados en lenguaje natural, con las palabras de quien los emite, y alguien debe leerlos, interpretarlos, decidir a qué área corresponden y establecer qué tan urgentes son. Cuando decenas o cientos de reportes coinciden durante una contingencia, esa lectura secuencial se convierte en un cuello de botella.

El efecto de ese cuello de botella no es administrativo. Un reporte crítico —por ejemplo, «hay una persona atrapada y el agua sigue subiendo»— puede permanecer en espera detrás de reportes menos graves por la única razón de haber llegado después, y en un dominio donde la variable relevante es el riesgo para la vida el orden de atención determina consecuencias humanas. A esta limitación de capacidad se añade una de método, constatada en el trabajo

de campo del apartado 3.1: la urgencia se determina hoy según el criterio individual de cada operadora, sin una regla explícita, de modo que dos reportes equivalentes pueden recibir prioridades distintas según quién los atienda.

El problema puede enunciarse entonces en los siguientes términos: no existe, para el español de México y en el contexto de una coordinación municipal de protección civil, un mecanismo que clasifique y ordene automáticamente los reportes ciudadanos según su nivel de riesgo, de modo que la atención se dirija primero a donde más se necesita y que el criterio aplicado sea explícito y verificable.

1.3 JUSTIFICACIÓN

La relevancia de atender este problema se sostiene en tres razones. La primera es el impacto potencial: en un dominio donde el tiempo de respuesta se vincula con la protección de la vida, reducir el intervalo entre la recepción de un reporte y su atención tiene un valor social directo. La segunda es la pertinencia tecnológica, pues la clasificación automática de texto corto es una tarea consolidada del procesamiento del lenguaje natural, con modelos preentrenados disponibles en español.

La tercera razón es la existencia de un vacío específico. La literatura de informática de crisis ha documentado ampliamente el análisis de mensajes ciudadanos durante desastres y ha liberado recursos y conjuntos de datos de referencia, aunque principalmente en inglés y sobre mensajes de redes sociales (Imran et al., 2015; Alam et al., 2021). Los trabajos disponibles en español para el dominio de emergencias son escasos, se concentran en otras variedades regionales y no abordan de manera conjunta la clasificación temática y la estimación de urgencia. Ese vacío es el que este trabajo aborda, y el apartado 3.3 lo documenta con detalle.

1.4 ALCANCE

El presente trabajo se delimita al desarrollo y la evaluación de un producto mínimo viable del Sistema Inteligente de Reportes de Emergencia Ciudadana, en adelante SIREC, y no de un sistema comercial completo ni de un despliegue gubernamental. El foco está en el componente de inteligencia artificial y en su integración operativa, de modo que la propuesta pueda demostrarse de principio a fin con un alcance abordable en el tiempo disponible. En concreto, el alcance comprende los siguientes elementos:

- Doble clasificación de cada reporte: en siete categorías temáticas —inundación, persona en riesgo, caída de poste o cable, deslave, incendio, daño estructural y otro— y en tres niveles de urgencia (alta, media y baja).
- Priorización operativa: los reportes se presentan en un panel ordenado por prioridad.
- Canal de entrada acotado: un formulario web como única vía de captura, dejando otros canales como trabajo futuro gracias a una arquitectura desacoplada.
- Caso de uso acotado: una coordinación municipal como caso de estudio, sin pretender la adopción institucional real durante el trabajo.

Quedan fuera del alcance la atención telefónica y la transcripción de voz, la gestión administrativa posterior al triaje, el despacho de recursos y el seguimiento del estatus del reporte por parte del ciudadano. Este último punto merece una mención explícita porque surgió como necesidad en el trabajo de campo: se registra como requerimiento de valor y línea futura, sin ampliar el alcance comprometido. La validación experimental completa, con sus resultados, corresponde al capítulo de validación y diseño experimental de la memoria final; en esta entrega se documenta su diseño en el apartado 3.7.

1.5 ESTRUCTURA DEL DOCUMENTO

El documento se organiza en tres capítulos, seguidos de las referencias bibliográficas y de un anexo. El capítulo 1 presenta el contexto, el problema, su justificación y el alcance. El capítulo 2 formula el objetivo general y los objetivos específicos que conducen a él, junto con la forma en que se medirá su cumplimiento. El capítulo 3 constituye el núcleo de esta entrega y desarrolla la concepción de la solución mediante la metodología Design Thinking.

Dentro de ese tercer capítulo, el apartado 3.1 documenta la etapa de empatía con los usuarios; el 3.2 traduce esos hallazgos en un problema accionable, con el criterio de urgencia y los criterios de desempeño; el 3.3 establece el fundamento teórico y revisa los trabajos previos para delimitar la brecha; el 3.4 genera y evalúa alternativas; el 3.5 describe el prototipo con su arquitectura y sus pantallas; el 3.6 justifica la selección mediante una matriz ponderada; y el 3.7 define el protocolo de evaluación. El anexo A recoge el instrumento de la encuesta ciudadana y sus resultados.

2. OBJETIVOS

Este capítulo es el puente entre el problema descrito y la innovación que se propone. El objetivo general expresa el efecto observable que se busca, la tecnología con la que se persigue y el modo en que se verificará su cumplimiento; los objetivos específicos descomponen ese propósito en pasos analizables por separado, en infinitivo y asociados a un resultado comprobable. Los umbrales numéricos que permiten declararlos cumplidos se detallan en el apartado 3.7.

2.1 OBJETIVO GENERAL

Reducir el tiempo y la variabilidad del triaje de reportes ciudadanos de emergencia en una coordinación municipal de protección civil, mediante el desarrollo y la evaluación de un producto mínimo viable que clasifique automáticamente cada reporte escrito en español de México por categoría temática y por nivel de urgencia —empleando un modelo de lenguaje preentrenado en español (BETO) ajustado mediante transferencia de aprendizaje— y que presente los reportes ordenados por prioridad en un panel de atención.

El cumplimiento de este objetivo se medirá de forma comparativa. El modelo ajustado se contrastará con un modelo de referencia clásico sobre el mismo conjunto de prueba y las mismas particiones, empleando la medida F1 macro y por clase, con atención particular a la exhaustividad en las clases críticas de persona en riesgo y urgencia alta. Se verificará además que la calidad del etiquetado alcance un acuerdo sustancial entre anotadores y que la latencia de la clasificación resulte compatible con el uso operativo. Los umbrales concretos de cada indicador se establecen en el apartado 3.7.

2.2 OBJETIVOS ESPECÍFICOS

1. Analizar el estado del arte en clasificación de reportes de emergencia mediante procesamiento del lenguaje natural y definir, a partir de esa revisión y del trabajo de campo, las siete categorías temáticas y los tres niveles de urgencia del proyecto, con la guía de etiquetado que los operacionaliza.
2. Construir un corpus propio de reportes en español de México, anonimizado y documentado, y validar su etiquetado mediante el coeficiente kappa de Cohen entre dos anotadores independientes.

3. Implementar un modelo de referencia clásico basado en TF-IDF con regresión logística y máquinas de vectores de soporte, como línea base obligatoria de comparación.
4. Ajustar mediante transferencia de aprendizaje el modelo BETO para las dos tareas de clasificación, atendiendo el desbalance entre clases y la calibración de la confianza.
5. Evaluar comparativamente ambos enfoques sobre las mismas particiones, con precisión, exhaustividad y medida F1 por clase y macro, matriz de confusión y conteo explícito de falsos negativos en las clases críticas.
6. Integrar y desplegar el sistema de extremo a extremo —formulario, clasificador y panel priorizado—, verificando su funcionamiento y midiendo la latencia de respuesta.

3. DESARROLLO CONCEPTUAL

Este capítulo documenta el proceso mediante el cual el equipo concibió la solución que propone, siguiendo la metodología Design Thinking. Se trata de un enfoque de innovación centrado en las personas: parte de comprender la necesidad real de quien vive el problema, la traduce en un reto accionable, la contrasta con el conocimiento existente, genera alternativas y las materializa en un prototipo evaluable. El énfasis del capítulo no está en explicar la metodología, sino en mostrar la evidencia de cómo se aplicó cada una de sus etapas al caso de SIREC.

La exposición sigue el orden en que el trabajo se realizó, según el detalle anticipado en el apartado 1.5: empatía con los usuarios, definición del problema, investigación de antecedentes, generación de alternativas, prototipo, selección razonada y diseño de la evaluación.

3.1 EMPATIZAR

La etapa de empatía persigue conocer al usuario final antes de proponerle una solución: sus necesidades, sus frustraciones y las condiciones en que trabaja o pide ayuda. En el caso de SIREC concurren dos usuarios con posiciones muy distintas frente al mismo suceso: la persona que reporta una emergencia y quien la recibe y decide qué hacer con ella. Este apartado describe las técnicas empleadas para comprender a ambos, los perfiles resultantes, el mapa de empatía y los hallazgos que orientaron el resto del trabajo.

3.1.1 Técnicas empleadas y perfiles de usuario

El equipo combinó tres técnicas complementarias. La primera fue el análisis del proceso y la observación documental del triaje manual en una coordinación municipal de protección civil, junto con la revisión de reportes ciudadanos reales publicados durante contingencias pasadas en Veracruz, tomados de redes sociales y de notas de prensa que los citan textualmente. La segunda fue una encuesta ciudadana anónima aplicada mediante un formulario en línea. La tercera consistió en dos visitas presenciales a instancias que reciben y priorizan reportes de emergencia.

Esta combinación responde a una limitación del acceso al campo: las instituciones de emergencia no facilitan el detalle de su operación interna, de modo que la voz del operador

se reconstruyó a partir de la observación y de las visitas. La tabla 2 sintetiza los dos perfiles con los que se trabajó.

Tabla 2. *Perfiles de usuario considerados en la etapa de empatía.*

Actor	Perfil y rol	Contexto de uso	Método de estudio
Operador de protección civil	Personal que recibe, lee y despacha los reportes; decide la prioridad de atención bajo presión de tiempo	Sala de coordinación durante una contingencia, con alto volumen simultáneo de reportes	Análisis del proceso, observación documental y dos visitas presenciales
Ciudadano reportante	Persona afectada o testigo que describe la emergencia con sus propias palabras	En campo, en situación de estrés, con redacción informal y modismos del español de México	Revisión de reportes públicos reales y encuesta anónima (n = 42)

Fuente: Elaboración propia.

La tabla 2 hace explícita una asimetría que condiciona el diseño: el ciudadano produce el texto en condiciones adversas y sin formato, mientras que el operador debe interpretarlo con rapidez. La solución no puede exigir al ciudadano que escriba mejor ni al operador que lea más rápido, sino que debe intervenir en el punto intermedio, ordenando la entrada antes de que llegue a la vista humana.

3.1.2 Acercamiento presencial a las autoridades de emergencia

Durante la semana del 13 de julio de 2026 el equipo realizó dos visitas presenciales a instancias que hoy reciben y priorizan reportes de emergencia: la Unidad de Protección Civil de la Alcaldía Venustiano Carranza, en la Ciudad de México, y la Comandancia de la Policía Municipal de Veracruz. El propósito era conocer, de la voz del usuario final, cómo se determina en la práctica el nivel de urgencia de cada reporte que ingresa.

En ambos casos se explicó que existe un sistema donde las operadoras registran las urgencias y, a partir de ese registro, se despachan las patrullas o los servicios. Sin embargo, de los comentarios del personal se desprende que son las propias operadoras quienes determinan el nivel de urgencia de forma subjetiva, con base en la conversación con quien reporta y sin

un criterio estandarizado explícito; al intentar profundizar en las herramientas empleadas, se mostraron renuentes por razones de privacidad institucional.

El acercamiento no permitió documentar un procedimiento formal, pero constituye un hallazgo central: la urgencia depende hoy del criterio individual de cada operadora y no de una regla reproducible. Esa ausencia es la necesidad que SIREC cubre mediante una guía de etiquetado explícita y un criterio validado entre anotadores, y la reticencia observada confirma la pertinencia de trabajar solo con datos anonimizados. Como limitación, el acceso restringido impidió cuantificar tiempos de triaje de la práctica actual, de modo que los criterios de éxito del apartado 3.7 se definen sobre el desempeño del sistema.

3.1.3 Resultados de la encuesta ciudadana

Para incorporar la voz del usuario final se aplicó una encuesta anónima mediante un formulario en línea, difundido entre personas que hubieran vivido o presenciado una emergencia. El instrumento consta de nueve preguntas, no recoge datos personales y se reproduce íntegro en el anexo A junto con la tabla de indicadores. Se obtuvieron 42 respuestas, de las cuales 35 corresponden a personas con experiencia directa.

Los resultados confirman el problema desde la perspectiva de quien reporta. El canal telefónico es hoy prácticamente el único empleado —22 menciones corresponden a la llamada al 9-1-1—, lo que respalda habilitar un formulario web como vía alterna de captura; la confianza en la respuesta es baja, con una media de 2.3 sobre 5 y casi dos tercios de las calificaciones en los dos valores inferiores; y las emergencias más mencionadas —inundación y caída de poste o cable— coinciden con los incidentes que el canal oficial registra con más frecuencia en Veracruz, donde en el primer semestre de 2026 se contabilizaron 1 123 llamadas por cables colgando y 376 por caída de poste (Centro Nacional de Información, 2026).

Conviene acotar el alcance de esta evidencia: es una muestra no probabilística, obtenida por difusión abierta del formulario, por lo que sus resultados no son generalizables. Su función es cualitativa —identificar dolores y expectativas reales que orienten el diseño—, no estimar parámetros poblacionales.

3.1.4 Mapa de empatía

A partir de las tres técnicas descritas se construyó el mapa de empatía que recoge el anexo B. El operador declara como dolores la lectura de decenas de reportes uno por uno, el riesgo de

que un caso crítico quede sepultado por el orden de llegada y la falta de un criterio común de urgencia; espera recibir los reportes ya ordenados por prioridad. El ciudadano señala las esperas y las llamadas sin respuesta, el exceso de preguntas en plena emergencia y la incertidumbre sobre la recepción de su reporte; espera que un caso con riesgo para la vida se atienda primero y poder seguir su estatus.

El contraste entre ambos perfiles revela que comparten una misma necesidad expresada de formas distintas, pues tanto el operador como el ciudadano piden que el orden de atención refleje el riesgo. Esa coincidencia justifica que la priorización automática sea el centro de la propuesta.

3.1.5 Hallazgos clave

El primer hallazgo es que el operador no necesita otra bandeja de mensajes, sino una lista ya ordenada por riesgo: las herramientas que se limitan a concentrar reportes le trasladan el trabajo de leerlos todos, que es el cuello de botella observado. El valor de la solución reside, por tanto, en la decisión de orden que entrega.

El segundo hallazgo señala cuál es la señal de urgencia determinante: la presencia de personas en peligro. De ello se desprende una consecuencia técnica que atraviesa todo el trabajo, y es que el error más costoso no es una confusión temática cualquiera, sino un falso negativo en las clases críticas; por eso la evaluación del apartado 3.7 privilegia la exhaustividad en esas clases. El tercero se refiere al lenguaje: los reportes reales emplean registro informal y modismos del español de México, escritos con prisa y sin corrección, lo que orienta la solución hacia un modelo preentrenado en español y ajustado con datos del propio dominio.

El cuarto hallazgo proviene de las visitas presenciales: la urgencia se fija hoy de manera subjetiva y sin criterio documentado, lo que convierte la guía de etiquetado del proyecto en un aporte por sí mismo, más allá del modelo. El quinto es una necesidad que el producto mínimo viable no cubre, pues varias personas encuestadas pidieron seguimiento y trazabilidad del estatus de su reporte; se registra como requerimiento de valor y línea de trabajo futuro, sin ampliar el alcance comprometido.

3.2 DEFINIR

Definir consiste en transformar los hallazgos de la etapa anterior en un problema claro y accionable, lo bastante concreto para poder resolverse y lo bastante medible para poder

evaluarse. Este apartado formula primero el reto en términos de preguntas de diseño, después precisa las clases que el sistema debe distinguir y el criterio con el que se asigna la urgencia, a continuación documenta el origen del corpus con el que se entrenará el modelo y, por último, traduce cada necesidad detectada en un requerimiento con su criterio de desempeño.

3.2.1 Formulación del reto

El reto se formuló mediante enunciados del tipo «¿Cómo podríamos...?», una técnica que obliga a expresar el problema como una posibilidad de diseño y no como una queja. El equipo redactó cinco enunciados a partir de los dolores documentados.

Los dos primeros abordan el cuello de botella y el orden de atención: cómo clasificar automáticamente cada reporte por tema y urgencia para que el operador no deba leerlos uno por uno, y cómo ordenarlos para que las situaciones con vidas en riesgo aparezcan siempre primero. Los tres restantes trasladan al plano técnico las restricciones detectadas: cómo maximizar la exhaustividad en las clases críticas, cómo construir y validar un corpus en español de México cuando no existe uno público, y cómo ofrecer la clasificación en tiempo real sin exponer datos sensibles ni depender de servicios de pago.

3.2.2 Categorías temáticas y criterio de urgencia

El sistema resuelve dos clasificaciones sobre un mismo texto: una asigna la categoría temática del incidente, con siete valores posibles, y otra el nivel de urgencia, con tres. La separación responde a que son decisiones de naturaleza distinta, pues la categoría determina qué área debe atender el reporte y la urgencia en qué orden se atiende; un mismo tema puede presentarse con niveles muy diferentes, de modo que tratarlas como una sola etiqueta compuesta sería menos informativo.

Las siete categorías temáticas son inundación, persona en riesgo, caída de poste o cable, deslave, incendio, daño estructural y otro. Su elección no es arbitraria: recoge los tipos de emergencia más mencionados por las personas encuestadas y coincide con incidentes que el canal oficial registra de forma habitual en Veracruz, como cables colgando, caída de poste, incendio de casa habitación, árbol caído, inundaciones y derrumbes (Centro Nacional de Información, 2026). La categoría «otro» funciona como clase de reserva y permite medir cuánto del flujo real queda fuera del alcance temático del prototipo.

El criterio de urgencia se define en función del riesgo para las personas, y el anexo B lo documenta con su definición operativa y ejemplos de frontera. La urgencia es alta cuando existe riesgo inminente para la vida o la integridad física, como una persona atrapada o un incendio con gente dentro; es media cuando hay una afectación relevante o una situación que puede escalar sin peligro inmediato, como un vehículo volcado sin personas atrapadas; y es baja en incidentes menores o informativos, como un encharcamiento. El principio rector, aplicado ante la duda, es que si hay personas expuestas se asigna el nivel superior.

Ese criterio cumple una función que va más allá de la exposición: al fijar por escrito qué cuenta como urgencia alta, convierte en regla explícita aquello que hoy depende del juicio de cada operadora. El mismo texto reciben los anotadores del corpus, de modo que el acuerdo entre ellos, medido con el coeficiente kappa, estima hasta qué punto el criterio es reproducible.

3.2.3 Origen y composición del corpus

Como no existe un corpus público de reportes de emergencia en español de México para este dominio, el equipo construye uno propio. Los reportes reales proceden de fuentes públicas relativas a contingencias ocurridas en Veracruz, en particular publicaciones en redes sociales y notas de prensa que citan textualmente reportes ciudadanos, y se anonimizan antes de su uso mediante la eliminación de nombres, números telefónicos y direcciones exactas. Esta decisión responde también a la preocupación por la privacidad que manifestaron las instituciones visitadas.

Ese conjunto se complementa con reportes sintéticos, declarados explícitamente como tales, cuya única función es reforzar la cobertura de las clases menos frecuentes durante el entrenamiento. La regla que el proyecto se impone es estricta: en ningún caso se evalúa el modelo con datos sintéticos, de modo que el conjunto de prueba es enteramente real. Su proporción y distribución por clase se reportan en el capítulo de metodología de la memoria final.

3.2.4 De la necesidad al criterio de desempeño

El último paso de esta etapa consiste en garantizar que ninguna necesidad quede sin una forma de comprobar que fue atendida. La tabla 3 recorre los hallazgos del apartado 3.1, los traduce en un requerimiento del sistema y asocia a cada uno un criterio de desempeño verificable, además de una prioridad que orientó el orden de construcción del prototipo.

Tabla 3. *Trazabilidad entre necesidad detectada, requerimiento y criterio de desempeño.*

Necesidad detectada	Requerimiento	Criterio de desempeño	Prioridad
Un caso crítico no puede quedar sepultado por el orden de llegada	Priorizar por urgencia y por la categoría de persona en riesgo	Exhaustividad alta en clases críticas, sin fugas hacia urgencia baja	Alta
El operador pierde tiempo leyendo todos los reportes	Clasificar tema y urgencia al ingresar el reporte	F1 por clase y macro superior a la del modelo de referencia	Alta
Los reportes usan el registro informal del español de México	Modelo preentrenado en español ajustado con datos del dominio	Mejora de la F1 macro frente a la línea base clásica	Media
Las etiquetas deben ser objetivas y reproducibles	Guía de etiquetado explícita y doble anotación independiente	Kappa de Cohen igual o superior a 0.60	Alta
La clasificación debe llegar a tiempo para ser útil	Clasificación en línea al momento de la captura	Latencia por debajo del umbral definido en 3.7	Media
No debe depender de servicios de pago ni exponer datos sensibles	Modelos abiertos en infraestructura propia	Costo nulo por predicción y sin envío de datos a terceros	Media

Fuente: Elaboración propia.

La tabla 3 opera como contrato interno del proyecto, pues cada fila enlaza una observación de campo con un indicador que se medirá en la evaluación. Conviene notar que dos de los seis criterios no dependen del modelo sino del método y de la arquitectura: el acuerdo entre anotadores y la independencia de servicios de pago no se resuelven con más entrenamiento.

3.3 INVESTIGACIÓN DE ANTECEDENTES

Este apartado conecta el problema con el conocimiento existente en dos movimientos. Primero establece el fundamento teórico que sustenta las decisiones técnicas del proyecto, recorriendo la representación del texto, los modelos de clasificación clásicos y neuronales, y los instrumentos con los que se mide tanto la calidad de las etiquetas como el desempeño del

sistema. Después revisa los trabajos previos que han abordado problemas equivalentes, para cerrar con la identificación de la brecha que SIREC cubre.

3.3.1 Fundamento teórico

La tarea que resuelve SIREC pertenece a la clasificación automática de texto, una de las aplicaciones más consolidadas del procesamiento del lenguaje natural. Formalmente, clasificar consiste en asignar a un documento una etiqueta tomada de un conjunto finito y predefinido, a partir de un modelo aprendido de ejemplos previamente etiquetados (Manning et al., 2008). Aquí el documento es un reporte de pocas oraciones y el problema se resuelve como dos clasificaciones independientes sobre el mismo texto: una de siete clases para la categoría temática y otra de tres para el nivel de urgencia.

El primer requisito es representar el texto de una forma que un algoritmo pueda procesar. La representación clásica es la bolsa de palabras, que describe cada documento por la presencia o frecuencia de sus términos y descarta el orden. Sobre ella, el esquema de ponderación TF-IDF asigna a cada término un peso que crece con su frecuencia en el documento y decrece con su frecuencia en la colección, de modo que las palabras muy repartidas pierden influencia y las distintivas la ganan (Salton y Buckley, 1988). Es una representación dispersa, interpretable y económica de calcular.

Su limitación resulta especialmente relevante en este dominio. Al prescindir del orden y tratar cada término como un símbolo independiente, TF-IDF no distingue entre «no hay personas atrapadas» y «hay personas atrapadas» más allá de la presencia del adverbio, ni reconoce como equivalentes dos formas de decir lo mismo con palabras distintas. En un corpus con registro informal y erratas, cada variante de escritura constituye además un término nuevo, lo que fragmenta la señal.

Sobre esta representación operan los modelos clásicos que el proyecto emplea como línea base. La regresión logística modela la probabilidad de cada clase mediante una combinación lineal de los pesos de los términos transformada por una función logística, y su extensión multinomial trata directamente problemas de más de dos clases. Las máquinas de vectores de soporte buscan el hiperplano que separa las clases con el mayor margen posible (Cortes y Vapnik, 1995) y han mostrado un desempeño sólido en categorización de texto, donde los rasgos son numerosos y los vectores dispersos (Joachims, 1998).

En problemas multiclase, estos modelos se extienden mediante estrategias de descomposición —uno contra el resto— o formulaciones multinomiales que estiman una distribución sobre todas las clases. La distinción determina si el modelo entrega una puntuación comparable entre clases, condición necesaria para ordenar los reportes por prioridad.

El segundo enfoque proviene del aprendizaje profundo aplicado al lenguaje. La arquitectura Transformer sustituyó la recurrencia por un mecanismo de atención que relaciona todas las posiciones de una secuencia entre sí, lo que permite capturar dependencias a distancia y paralelizar el entrenamiento (Vaswani et al., 2017). Sobre ella, BERT introdujo el preentrenamiento bidireccional profundo mediante tareas autosupervisadas sobre grandes volúmenes de texto sin etiquetar (Devlin et al., 2019). La diferencia esencial respecto de TF-IDF es que produce representaciones contextuales: el vector de una palabra depende de las que la rodean, propiedad decisiva cuando la negación y el contexto determinan la urgencia.

Un modelo preentrenado en inglés, sin embargo, no resuelve un problema en español. BETO es un modelo de la familia BERT preentrenado con un corpus extenso en español, con resultados competitivos en tareas de esa lengua (Cañete et al., 2020). Su disponibilidad como modelo abierto es determinante aquí por dos razones: permite trabajar en la lengua del corpus y hace posible ejecutar la clasificación en infraestructura propia, sin enviar los reportes a terceros, lo que responde a la preocupación por la privacidad recogida en el trabajo de campo.

Estos modelos no operan sobre palabras completas sino sobre subpalabras. Los algoritmos de tokenización de subpalabras, como la codificación por pares de bytes (Sennrich et al., 2016) y las implementaciones independientes del idioma que la generalizan (Kudo y Richardson, 2018), descomponen cada término en unidades frecuentes, de modo que una palabra desconocida se representa como combinación de fragmentos conocidos en lugar de perderse. Con modismos, abreviaturas y erratas, esta propiedad reduce el problema del vocabulario fuera de rango que afecta a las representaciones clásicas.

El aprovechamiento del modelo preentrenado para una tarea concreta se realiza mediante transferencia de aprendizaje. El procedimiento habitual, el ajuste fino, añade una capa de clasificación sobre la representación del modelo y continúa el entrenamiento con los datos etiquetados de la tarea, actualizando los pesos preentrenados con una tasa de aprendizaje

reducida (Howard y Ruder, 2018). Requiere órdenes de magnitud menos ejemplos que entrenar desde cero —decisivo cuando el corpus se construye a mano— y hoy es un estándar de la práctica gracias a las bibliotecas que agrupan modelos y rutinas de ajuste (Wolf et al., 2020).

Un problema que este dominio impone de manera inevitable es el desbalance entre clases: las emergencias más graves son, afortunadamente, las menos frecuentes, de modo que las clases críticas están subrepresentadas en cualquier muestra natural. El desbalance sesga a los clasificadores hacia las clases mayoritarias y degrada su desempeño en las minoritarias (Japkowicz y Stephen, 2002); entre las estrategias para atenuarlo están el remuestreo, la generación de ejemplos sintéticos de las clases escasas (Chawla et al., 2002) y la ponderación de la función de pérdida. En SIREC el problema se agrava porque la clase minoritaria es precisamente la que no puede fallar.

Cuando la salida del modelo se muestra a una persona, además de acertar la clase importa que la confianza asociada sea creíble. Las redes neuronales profundas tienden a estar mal calibradas y a producir probabilidades más altas que su acierto real, aunque existen procedimientos posteriores al entrenamiento que corrigen ese sesgo (Guo et al., 2017). Para el panel del operador la propiedad es funcional: la confianza es el criterio con el que se decide qué predicciones se marcan para revisión humana, de modo que una confianza inflada convertiría ese mecanismo en un adorno.

La evaluación del desempeño se apoya en métricas derivadas de la matriz de confusión. La precisión indica qué proporción de las predicciones de una clase es correcta; la exhaustividad, qué proporción de los casos reales de esa clase fue recuperada; y la medida F1 resume ambas en su media armónica. En problemas multiclase se calculan por clase y se agregan: el promedio macro otorga igual peso a cada clase con independencia de su frecuencia, a diferencia del micro, que favorece a las clases numerosas (Sokolova y Lapalme, 2009). La elección tiene consecuencias operativas, pues un sistema que acertara todos los encharcamientos y fallara todas las personas atrapadas exhibiría una exactitud elevada y sería inservible.

Finalmente, ninguna de estas métricas tiene sentido si las etiquetas contra las que se comparan no son confiables. La concordancia entre anotadores humanos se mide con el coeficiente kappa de Cohen, que descuenta el acuerdo atribuible al azar (Cohen, 1960); sus valores se interpretan mediante escalas convencionales que sitúan el acuerdo sustancial por

encima de 0.60 (Landis y Koch, 1977), si bien la literatura advierte que esos cortes son orientativos y deben leerse junto con la guía de anotación (Artstein y Poesio, 2008). Si la urgencia se asigna hoy de forma subjetiva, medir ese acuerdo es la evidencia de que el criterio propuesto resulta comunicable y reproducible.

3.3.2 Trabajos previos

La revisión se organiza de lo general a lo particular: los trabajos que consolidaron el problema y produjeron los recursos de referencia del área, los que abordaron la clasificación con modelos neuronales y, por último, los dos antecedentes más próximos por lengua y dominio, ambos latinoamericanos. De cada uno se indica el problema atendido, el contexto y el idioma, los datos y su etiquetado, los modelos y métricas, los resultados y limitaciones, y su relación con este trabajo.

El trabajo de Imran et al. (2015) es el punto de partida obligado: una revisión sistemática, publicada en ACM Computing Surveys, del procesamiento de mensajes de redes sociales durante emergencias masivas. No propone un sistema, sino que organiza el campo, identifica las etapas de la cadena de procesamiento —recolección, filtrado, clasificación, extracción y agregación— y señala los problemas abiertos, entre ellos la escasez de conjuntos etiquetados y la dificultad de operar en tiempo real. Su contexto es mayoritariamente anglófono y su unidad de análisis es el mensaje público, no el reporte dirigido a una autoridad; por su naturaleza no aporta corpus ni métricas propias. Su valor para SIREC es de encuadre y de vocabulario conceptual.

En la línea de los recursos, Olteanu et al. (2014) presentaron CrisisLex, un léxico para recolectar y filtrar mensajes de crisis en inglés. Partieron de mensajes de varias crisis anotados manualmente por un lingüista y un especialista en gestión de emergencias, y produjeron un recurso de alrededor de 7 200 términos organizados en 23 categorías informativas, combinando anotación experta con trabajo colaborativo.

El resultado reportado es una mejora sustancial de la exhaustividad en la recolección al añadir el léxico a las palabras clave elegidas por expertos. Su limitación frente a este trabajo es doble: opera en la fase de filtrado y no en la asignación de urgencia, y su naturaleza léxica lo hace dependiente del idioma y de la variedad regional.

Alam et al. (2021) abordaron la fragmentación de los conjuntos de datos del área. Su trabajo, CrisisBench, consolida ocho fuentes anotadas en un punto de referencia común, con aproximadamente 166 100 mensajes para determinar si un mensaje es informativo y 141 500 para la clasificación de categorías humanitarias, unificando etiquetas heterogéneas y fijando particiones estándar.

Los autores comparan modelos clásicos y basados en transformadores sobre esas particiones y muestran que un conjunto consolidado permite entrenar modelos más sólidos. Sus limitaciones aquí son el idioma, predominantemente inglés, y las etiquetas, que corresponden a categorías humanitarias y no a un criterio de urgencia operativa municipal; su aportación metodológica, en cambio, es directa, pues la práctica de fijar particiones reproducibles y comparar contra líneas base sobre los mismos datos es la que adopta el apartado 3.7.

En cuanto a los modelos, Nguyen et al. (2016) aplicaron redes neuronales convolucionales a la clasificación de mensajes de crisis en inglés, en tareas binarias y multiclase, sobre datos de eventos reales. Su resultado principal es que los modelos neuronales superan a los métodos basados en rasgos diseñados manualmente y eliminan la necesidad de esa ingeniería, lo que reduce el trabajo de adaptación al cambiar de dominio o de evento. Sus limitaciones son las de la generación anterior a los modelos preentrenados: la representación no es contextual y el desempeño depende de contar con suficientes ejemplos etiquetados del evento. Para SIREC constituye la continuidad argumental que el ajuste fino lleva un paso más allá.

El antecedente más próximo por dominio es el de Paltin et al. (2025), quienes desarrollaron un modelo para el servicio de emergencias ECU 911 de Ecuador que clasifica los incidentes e infiere su prioridad. Opera sobre transcripciones de llamadas en español y combina procesamiento del lenguaje natural con modelado semántico basado en ontologías y reglas lógicas, de modo que la asignación de prioridad resulta explicable a partir de las relaciones declaradas. Su fortaleza es esa trazabilidad, valiosa donde la decisión debe justificarse; sus limitaciones son que el paradigma es simbólico —generalizar ante expresiones no previstas depende de la cobertura de la ontología—, que la entrada es voz transcrita y que la variedad del español es la ecuatoriana.

El segundo antecedente regional es el de Franco Cantos (2024), una tesis de maestría que construyó un modelo para identificar publicaciones de emergencia en la red social X para el caso de Ecuador. El autor conformó un corpus propio en español ecuatoriano, lo etiquetó

manualmente y entrenó modelos clásicos sobre representaciones TF-IDF —regresión logística y máquinas de vectores de soporte—, evaluando con las métricas habituales de clasificación.

La tarea resuelta es binaria, distinguir si una publicación corresponde o no a una emergencia, de modo que no aborda la categoría temática con varias clases ni el nivel de urgencia. El propio trabajo señala como línea futura la incorporación de modelos basados en transformadores, recomendación que este proyecto retoma. Su relación con SIREC es doble: evidencia que un corpus propio en español, aunque modesto, permite entrenar clasificadores útiles, y sitúa el modelo clásico TF-IDF como la línea base razonable de comparación. La tabla 4 sintetiza la comparación y añade la posición de la propuesta.

Tabla 4. *Síntesis comparativa de los trabajos previos revisados.*

Trabajo	Problema y contexto	Idioma y datos	Modelos y métricas	Limitaciones frente a SIREC
Imran et al. (2015)	Revisión del procesamiento de mensajes en emergencias masivas	Inglés; sin corpus propio	No aplica; sistematiza métodos	No es solución operativa; no aborda urgencia ni español de México
Olteanu et al. (2014)	Recolección y filtrado de mensajes de crisis con léxico	Inglés; ≈7 200 términos en 23 categorías	Enfoque léxico; mejora la exhaustividad al recolectar	Actúa en el filtrado, no en la urgencia; dependiente del idioma
Nguyen et al. (2016)	Clasificación binaria y multiclase de mensajes de crisis	Inglés; datos de eventos reales	Redes convolucionales; superan rasgos manuales	Representación no contextual; español no contemplado
Alam et al. (2021)	Consolidación de conjuntos de datos en un punto de referencia	Inglés; ≈166 100 y ≈141 500 mensajes de ocho fuentes	Clásicos y transformadores con particiones estándar	Etiquetas humanitarias, no de urgencia operativa
Paltin et al. (2025)	Clasificación e inferencia de prioridad en el ECU 911	Español de Ecuador; transcripciones de llamadas (tamaño no reportado)	PLN con ontologías y reglas; prioridad explicable	Paradigma simbólico; entrada de voz; otra variedad del español

Franco Cantos (2024)	Identificación de publicaciones de emergencia en la red social X	Español de Ecuador; corpus propio etiquetado a mano	TF-IDF con regresión logística y SVM	Tarea binaria; sin categoría ni urgencia; recomienda transformadores
SIREC (propuesta)	Doble clasificación y priorización en una coordinación municipal	Español de México; corpus propio anonimizado, prueba 100 % real	BETO ajustado frente a línea base TF-IDF; F1, kappa y latencia	—

Fuente: Elaboración propia.

Los trabajos revisados confirman la relevancia del problema y aportan piezas valiosas: un marco conceptual consolidado, recursos y conjuntos de datos de referencia, evidencia de que los modelos que aprenden representaciones superan a los basados en rasgos manuales, y dos experiencias hispanohablantes en el dominio. Ninguno, sin embargo, resuelve el problema planteado en este documento.

La brecha se sitúa en la intersección de cuatro condiciones que ningún antecedente satisface a la vez. La primera es la doble clasificación por categoría temática y por nivel de urgencia sobre el mismo reporte, cuando los trabajos disponibles resuelven una tarea binaria, una clasificación temática o una inferencia de prioridad por reglas. La segunda es la variedad lingüística, pues el español de México no está representado en los corpus del área.

La tercera es el canal y el destinatario, ya que aquí se trata de reportes escritos dirigidos a una autoridad municipal cuyo resultado debe integrarse en el flujo de trabajo de quien atiende. La cuarta es la existencia de un criterio de urgencia explícito y medido: ninguno de los trabajos reporta el acuerdo entre anotadores sobre esa asignación.

3.4 IDEAR

Con la necesidad comprendida y los antecedentes revisados, la etapa de ideación consiste en abrir el abanico de soluciones posibles antes de comprometerse con una. El equipo consideró cuatro enfoques capaces, en principio, de resolver la clasificación y la priorización de reportes, y los valoró con cinco criterios: impacto o precisión esperada, viabilidad técnica, costo, esfuerzo asumible en el plazo disponible y alineación con los principios de adopción responsable de la inteligencia artificial, entendidos en el marco MELDS de Daugherty y Wilson (2018), cuyo pilar de liderazgo incorpora esa dimensión.

La primera alternativa consiste en un sistema de reglas basado en diccionarios de palabras clave que asignan categoría y urgencia. Su atractivo es la simplicidad: no requiere datos etiquetados ni entrenamiento, y su comportamiento es completamente predecible. Su debilidad es justamente lo que el trabajo de campo identificó como característico del dominio, pues el lenguaje informal, las variantes de escritura y la negación desbordan cualquier lista de términos, y mantener las reglas al día se vuelve una tarea sin fin.

La segunda alternativa es un modelo clásico de aprendizaje supervisado sobre representaciones TF-IDF, con regresión logística o máquinas de vectores de soporte. Ofrece un desempeño razonable con pocos recursos de cómputo, es interpretable y constituye el enfoque que la literatura hispanohablante del dominio ya ha empleado (Franco Cantos, 2024). Su limitación es la ausencia de contexto en la representación, que en este problema afecta precisamente a los casos donde la urgencia depende de la negación o del entorno de la frase.

La tercera alternativa es el ajuste fino de un modelo de lenguaje preentrenado en español, concretamente BETO, para las dos tareas de clasificación. Es la opción con mayor impacto esperado, porque aporta representaciones contextuales en la lengua del corpus, y resulta viable con recursos modestos gracias a la transferencia de aprendizaje. Su costo es un mayor esfuerzo de implementación y la necesidad de infraestructura para servir el modelo, además de la exigencia de cuidar el desbalance y la calibración de la confianza.

La cuarta alternativa consiste en delegar la clasificación en un servicio comercial de inteligencia artificial mediante su interfaz de programación. Reduciría drásticamente el esfuerzo de desarrollo, pero introduce tres inconvenientes decisivos: un costo por predicción que compromete la sostenibilidad de la solución en una coordinación municipal, la salida de los reportes hacia un tercero —incompatible con la preocupación por la privacidad manifestada en las visitas— y la dependencia de un proveedor externo. La tabla 5 resume la valoración de las cuatro alternativas.

Tabla 5. *Alternativas de solución consideradas y su valoración cualitativa.*

N.º	Enfoque	Impacto esperado	Esfuerzo	Viabilidad
1	Reglas por palabras clave	Bajo: frágil ante el lenguaje informal	Bajo	Alta

2	Modelo clásico de línea base (TF-IDF con regresión logística y SVM)	Medio	Medio	Alta
3	Transformador en español: ajuste fino de BETO	Alto	Alto	Media-alta
4	Servicio de pago administrado de un tercero	Medio-alto	Bajo	Baja: costo, dependencia y salida de datos

Fuente: Elaboración propia.

La lectura de la tabla 5 conduce a una decisión combinada. La alternativa 4 se descarta porque incumple el principio de trabajar con herramientas abiertas y sin costo por uso, y porque reduciría la aportación académica a integrar un servicio ajeno; la alternativa 1 resulta insuficiente por sí sola, aunque conserva utilidad como modo de arranque. Las alternativas 2 y 3 no compiten sino que se complementan: el modelo clásico se adopta como línea base obligatoria, porque sin punto de comparación no puede afirmarse que el modelo neuronal aporte algo, y BETO ajustado como clasificador principal por su mayor impacto esperado en español.


3.5 PROTOTIPAR

Prototipar consiste en construir una primera versión del producto que permita poner a prueba las hipótesis del proyecto. Para SIREC se eligió un prototipo de alta fidelidad, es decir, un producto mínimo viable funcional de extremo a extremo, y no un conjunto de bocetos estáticos. La justificación es directa: el valor de la propuesta depende de comprobar que un reporte real puede clasificarse y priorizarse en el momento en que se recibe, y eso solo puede evidenciarse con un sistema que efectivamente funcione.

3.5.1 Arquitectura del prototipo

El prototipo se organiza en cinco módulos con responsabilidades delimitadas, comunicados mediante interfaces explícitas. La figura 1 muestra esa arquitectura con las entradas y salidas rotuladas sobre cada conexión, de modo que puede seguirse el recorrido completo de un reporte desde su captura hasta su aparición en el panel de atención.

Figura 1. Arquitectura del prototipo de SIREC, con módulos, entradas, salidas y conexiones.



Fuente: Elaboración propia.

El recorrido comienza en el módulo 1, un formulario público donde el ciudadano describe la emergencia en texto libre, sin catálogos que elegir. El módulo 2 es la interfaz de programación desarrollada en .NET 8, que recibe el reporte, lo persiste y orquesta la clasificación. El módulo 3 es el microservicio escrito en Python con FastAPI, que expone el modelo BETO ajustado y la línea base clásica y devuelve la categoría, el nivel de urgencia y la confianza de cada predicción. El módulo 4 es la base de datos PostgreSQL, que almacena el reporte, las etiquetas asignadas, la confianza y la traza de las correcciones humanas posteriores. El módulo 5 es el panel del operador, que consulta los reportes ya ordenados por prioridad. La separación del clasificador en un servicio independiente permite sustituir el modelo sin modificar la aplicación e incorporar en el futuro otros canales de entrada. Además, todo el procesamiento ocurre en infraestructura propia, de modo que el texto del reporte no se envía a terceros: es la respuesta directa a la reticencia que las instituciones visitadas manifestaron sobre el manejo de información sensible.

3.5.2 Pantallas principales

El prototipo tiene dos pantallas, una por cada usuario identificado en la etapa de empatía. La figura 2 presenta el formulario de captura destinado al ciudadano, cuyo diseño responde al dolor más citado en la encuesta: la exigencia de responder muchas preguntas en plena emergencia. Por eso el campo principal es un área de texto libre y los demás datos son opcionales.

Figura 2. Formulario público de captura del reporte ciudadano.

SIREC · Reportar una emergencia

Describe lo que está ocurriendo

«Se cayó un poste y hay cables sobre la banqueta, una señora quedó atrapada entre el poste y su carro»

Texto libre · sin formularios rígidos ni catálogos que elegir

Ubicación aproximada (opcional)

Calle o referencia cercana

Teléfono de contacto (opcional)

10 dígitos

Enviar reporte

Reporte recibido. Se clasificó como «persona en riesgo» con urgencia alta y ya aparece en el panel de atención.

Fuente: Elaboración propia.

Tras el envío, la pantalla confirma la recepción e informa de la clasificación asignada, lo que atiende parcialmente la incertidumbre sobre si el reporte fue recibido, aunque el seguimiento posterior del estatus queda fuera del alcance de esta versión. La figura 3 muestra el panel del operador, donde se materializa la aportación central del sistema.

Figura 3. Panel del operador con los reportes ordenados por prioridad.

SIREC · Panel del operador					Ordenado por prioridad
Urgencia	Categoría	Reporte	Confianza	Estado	Revisión
ALTA	Persona en riesgo	«hay una señora atrapada entre el poste»	0.96	Sin atender	
ALTA	Inundación	«el agua entró a la casa y sigue subiendo»	0.91	Sin atender	
MEDIA	Poste o cable caído	«se cayó un cable, nadie cerca»	0.58	Sin atender	revisar
MEDIA	Daño estructural	«se cuarteo la barda de la escuela»	0.87	En atención	
La franja lateral y la etiqueta indican la urgencia; la barra muestra la confianza del modelo. Cuando la confianza queda por debajo del umbral, el reporte se marca para revisión humana sin perder su posición en la lista. El operador puede corregir la clasificación, y esa corrección se registra como traza de retroalimentación.					

Fuente: Elaboración propia.

El panel presenta los reportes en una sola lista ordenada por urgencia y, dentro de cada nivel, por antigüedad, de modo que la lista ya expresa la decisión de qué leer primero. La tabla 6

resume las funcionalidades del prototipo, el usuario al que sirve cada una y el beneficio que obtiene.

Tabla 6. *Funcionalidades del prototipo, usuario destinatario y beneficio.*

Funcionalidad	Usuario	Beneficio
Enviar un reporte en lenguaje natural	Ciudadano reportante	Comunicar la emergencia sin formatos rígidos ni catálogos
Clasificar tema y urgencia al momento de la captura	Sistema, en favor del operador	Evita la lectura y el triaje manual de cada reporte
Consultar los reportes ordenados por prioridad	Operador de protección civil	Atiende primero lo más crítico, con independencia del orden de llegada
Consultar el detalle de un reporte	Operador de protección civil	Decide y despacha con el contexto completo del caso
Corregir la clasificación de un reporte	Operador de protección civil	Conserva el control de la decisión y genera traza de retroalimentación

Fuente: Elaboración propia.

3.5.3 Presentación de la prioridad, la confianza y la revisión humana

La forma en que el panel comunica sus resultados es parte del diseño, porque de ella depende que el operador pueda confiar en el sistema sin delegarle la decisión. La prioridad se comunica por triple redundancia —el orden de la lista, una etiqueta textual con el nivel y una franja de color en el costado del renglón—, lo que evita depender exclusivamente del color y favorece la accesibilidad.

La confianza del modelo se muestra junto a cada predicción, en valor numérico y en una barra proporcional. Su función es permitir al operador calibrar cuánto apoyarse en la sugerencia: una clasificación con confianza alta puede aceptarse sin más, mientras que una confianza baja invita a leer el texto completo antes de decidir. Para que esta señal sea honesta, el modelo requiere un procedimiento de calibración posterior al entrenamiento, según se explicó en el fundamento teórico (Guo et al., 2017).

Cuando la confianza queda por debajo de un umbral configurable, el reporte se marca para revisión humana sin alterar su posición en la lista: solo se advierte que la sugerencia automática es débil. El mecanismo reconoce una restricción que el proyecto asume desde el principio, y es que la decisión final sobre una emergencia debe permanecer en manos de una persona.

El tratamiento de los errores sigue la misma lógica de precaución. Ante un fallo del microservicio de clasificación, el reporte se guarda íntegro y se muestra en el panel sin etiquetas, marcado como pendiente de clasificar, en lugar de descartarse o de recibir una etiqueta arbitraria: perder un reporte es un riesgo inaceptable, mientras que mostrarlo sin clasificar solo devuelve al operador a su situación actual. En sentido inverso, ante la duda entre dos niveles de urgencia, la guía de etiquetado obliga a elegir el superior, criterio que se refleja también en el comportamiento del sistema.

Por último, cada corrección del operador queda registrada junto con la predicción original. Esa traza permite auditar el comportamiento del modelo en operación y constituye la fuente natural de ejemplos para reentrenarlo con datos del propio contexto de uso.

3.6 SELECCIÓN DE PROTOTIPO

La selección de prototipo justifica, mediante una matriz de criterios ponderados, cuál de las alternativas conviene desarrollar y validar. Antes de presentar los resultados es necesario declarar cómo se construyó la matriz, porque de ello depende que sus conclusiones sean interpretables: qué criterios se emplearon y con qué peso, qué escala se aplicó, quién asignó las puntuaciones y sobre qué evidencia.

Los cinco criterios provienen de las restricciones documentadas en las etapas anteriores. El impacto o precisión esperada recibe el mayor peso, 30 %, porque el valor del sistema depende de que la clasificación sea correcta, en particular en las clases críticas. La viabilidad técnica y el costo reciben 20 % cada uno: la primera porque una solución inviable en el plazo disponible no es una solución, y el segundo porque el destinatario es una coordinación municipal con presupuesto acotado. La adopción responsable de la inteligencia artificial y el esfuerzo asumible reciben 15 % cada uno.

La escala de valoración va de 1 a 5, donde 1 es la condición menos favorable. En el criterio de costo un valor alto significa menor costo, de modo que todos los criterios se leen en el mismo

sentido; el puntaje final es la suma de las valoraciones multiplicadas por el peso de cada criterio.

Las puntuaciones fueron asignadas por consenso entre los tres integrantes del equipo en una sesión dedicada a ello: cada integrante propuso un valor y, cuando la discrepancia superó un punto, se discutió hasta acordar una cifra única. La evidencia que las respaldó fue de tres tipos: el trabajo de campo y la encuesta para el impacto esperado, la revisión de antecedentes del apartado 3.3 para la precisión atribuible a cada enfoque, y las condiciones reales del proyecto —infraestructura, plazo y ausencia de presupuesto— para viabilidad, costo y esfuerzo. La tabla 7 presenta el resultado.

Tabla 7. *Matriz de selección ponderada de las alternativas de solución.*

Criterio (peso)	1. Reglas por palabras clave	2. Línea base clásica	3. MVP funcional con BETO	4. Servicio de pago
Impacto y precisión esperada (30 %)	2	3	5	4
Viabilidad técnica (20 %)	5	5	4	3
Costo, donde mayor es mejor (20 %)	5	5	4	1
Adopción responsable de la IA (15 %)	3	4	5	2
Esfuerzo asumible en el plazo (15 %)	5	4	3	4
Puntaje ponderado	3.65	4.05	4.40	2.90

Fuente: Elaboración propia; escala de 1 (menos favorable) a 5 (más favorable), valorada por consenso de los tres integrantes del equipo.

La tabla 7 confirma la decisión anticipada en el apartado anterior. El producto mínimo viable con BETO obtiene el puntaje más alto, 4.40, porque compensa su mayor esfuerzo de implementación con la mejor valoración en los dos criterios de mayor peso combinado: el impacto esperado y la adopción responsable, esta última favorecida por ejecutarse en

infraestructura propia y sin envío de datos a terceros. La línea base clásica queda en segundo lugar con 4.05, resultado coherente con su papel en el proyecto.

El servicio de pago obtiene el puntaje más bajo, 2.90, penalizado por el costo por predicción y la dependencia externa, y las reglas por palabras clave alcanzan 3.65 gracias a su viabilidad y costo nulo, aunque su impacto insuficiente las descarta como solución principal. Conviene reconocer que estas valoraciones son juicios expertos del equipo y no mediciones: su función es hacer explícito y discutible el razonamiento de la decisión.

En consecuencia, se selecciona el producto mínimo viable web con BETO como modelo principal, servido por el microservicio de clasificación, acompañado de la línea base clásica como referencia obligatoria y con un panel del operador ordenado por urgencia. La comprobación empírica de esta elección corresponde a la evaluación que se describe a continuación.

3.7 DISEÑO DE LA EVALUACIÓN

Este último apartado define cómo se comprobará que la solución funciona, antes de haberla evaluado: anticipar el diseño fija los criterios con los que se juzgará el resultado sin conocerlo, lo que evita ajustar después las expectativas a lo conseguido. Se describen el protocolo comparativo, las particiones, las métricas, los criterios mínimos de éxito y las amenazas a la validez; la ejecución y sus resultados corresponden al capítulo de validación de la memoria final.

3.7.1 Protocolo comparativo y particiones reproducibles

La evaluación es comparativa por diseño. Se contrastan dos enfoques sobre exactamente los mismos datos: la línea base clásica, que combina la representación TF-IDF con regresión logística y con máquinas de vectores de soporte, y el modelo BETO ajustado mediante transferencia de aprendizaje. Ambos resuelven las dos tareas del proyecto y reciben el mismo texto de entrada, con idéntico preprocesamiento, para que la diferencia observada sea atribuible al modelo y no al tratamiento de los datos.

El corpus se divide en tres particiones estratificadas por clase, con proporciones aproximadas de 70 % para entrenamiento, 15 % para validación y 15 % para prueba. La estratificación es necesaria porque las clases críticas son minoritarias y una división aleatoria simple podría dejarlas sin representación suficiente en la prueba. Las particiones se generan una sola vez

con una semilla fija que se documenta en el repositorio, y se reutilizan sin modificación en todos los experimentos, de modo que cualquier persona pueda reproducir los mismos conjuntos.

Tres reglas adicionales protegen la validez de la comparación: el conjunto de prueba se compone solo de reportes reales, se emplea una única vez al final —las decisiones de ajuste se toman sobre la partición de validación— y ningún reporte aparece en más de una partición, comprobación necesaria porque un mismo hecho puede reportarse en términos casi idénticos.

3.7.2 Métricas seleccionadas

El desempeño se reporta con precisión, exhaustividad y medida F1 por clase, agregadas mediante promedio macro, que otorga igual importancia a cada clase con independencia de su frecuencia (Sokolova y Lapalme, 2009). Se descarta la exactitud global como métrica principal porque, con clases desbalanceadas, un modelo puede exhibirla elevada mientras falla sistemáticamente en las clases que más importan.

A las métricas agregadas se añaden dos instrumentos de diagnóstico: la matriz de confusión de cada tarea, que permite identificar qué clases se confunden entre sí y no solo cuánto se falla, y el conteo absoluto de falsos negativos en las clases críticas —reportes de persona en riesgo clasificados como otra categoría y reportes de urgencia alta clasificados con urgencia menor—. Se reporta el número de casos y no solo la proporción, porque en conjuntos pequeños un porcentaje bajo puede ocultar sucesos graves.

La evaluación incorpora además dos dimensiones ajenas al modelo: la calidad del etiquetado, medida con el coeficiente kappa de Cohen entre dos anotadores independientes que aplican la guía sobre una misma muestra (Cohen, 1960), y el tiempo de respuesta de extremo a extremo, desde el envío del formulario hasta la aparición del reporte en el panel, reportando la mediana y el percentil 95 en lugar del promedio.

3.7.3 Criterios mínimos de éxito

La tabla 8 fija los umbrales que permitirán declarar cumplido cada objetivo. Son compromisos asumidos antes de ejecutar la evaluación, de manera que el resultado sea verificable y no interpretable: cuando un indicador no alcance su umbral, el capítulo de validación deberá documentarlo como tal y discutir la causa, en lugar de reformular el criterio.

Tabla 8. *Criterios mínimos de éxito de la evaluación.*

Indicador	Umbral comprometido	Justificación del umbral
F1 macro en la clasificación temática (7 clases)	≥ 0.75 y al menos 5 puntos porcentuales sobre la mejor línea base	La mejora debe ser apreciable para justificar el enfoque neuronal
F1 macro en la clasificación de urgencia (3 clases)	≥ 0.70 , superando a la mejor línea base	Tarea más subjetiva; umbral menor, pero se exige la mejora
Exhaustividad en la categoría «persona en riesgo»	≥ 0.90	Es la clase donde omitir un caso tiene la consecuencia más grave
Exhaustividad en el nivel «urgencia alta»	≥ 0.90	Determina el orden de atención de los casos con riesgo para la vida
Falsos negativos graves (urgencia alta clasificada como baja)	0 casos en la prueba	Un salto de dos niveles sepulta un caso crítico al final de la lista
Acuerdo entre anotadores (kappa de Cohen), ambas tareas	≥ 0.60	Umbral convencional de acuerdo sustancial (Landis y Koch, 1977)
Latencia de extremo a extremo, percentil 95	≤ 3 s, clasificación por debajo de 1.5 s	El reporte debe priorizarse sin espera perceptible
Reportes reales asignados a la categoría «otro»	≤ 15 % de la prueba	Un valor mayor indicaría que las siete categorías no cubren el flujo real

Fuente: Elaboración propia.

Conviene declarar por anticipado las amenazas a la validez de este diseño. La principal es el tamaño del corpus, que al construirse manualmente será muy inferior a los conjuntos consolidados del área (Alam et al., 2021), lo que obliga a acompañar cada comparación del tamaño de la clase en la prueba; la segunda, que los datos provienen de fuentes públicas y no del canal institucional; y la tercera, el uso de ejemplos sintéticos en el entrenamiento, frente al que mantener la prueba enteramente real es la salvaguarda adoptada. Si el kappa resultara inferior al umbral, la conclusión correcta no sería descartar el enfoque, sino revisar la guía y reetiquetar.

Referencias bibliográficas

- Alam, F., Sajjad, H., Imran, M., y Ofli, F. (2021). CrisisBench: Benchmarking crisis-related social media datasets for humanitarian information processing. *Proceedings of the International AAAI Conference on Web and Social Media*, 15, 923-932. <https://ojs.aaai.org/index.php/ICWSM/article/view/18115>
- Artstein, R., y Poesio, M. (2008). Inter-coder agreement for computational linguistics. *Computational Linguistics*, 34(4), 555-596. <https://doi.org/10.1162/coli.07-034-R2>
- Cañete, J., Chaperon, G., Fuentes, R., Ho, J.-H., Kang, H., y Pérez, J. (2020). Spanish pre-trained BERT model and evaluation data. PML4DC at ICLR 2020. <https://users.dcc.uchile.cl/~jperez/papers/pml4dc2020.pdf>
- Centro Nacional de Información. (2025). Estadística nacional de llamadas de emergencia al número único 9-1-1: cifras con corte al 31 de diciembre de 2024. Secretariado Ejecutivo del Sistema Nacional de Seguridad Pública. <https://www.gob.mx/911/articulos/estadistica-nacional-del-numero-de-atencion-de-llamadas-de-emergencia-9-1-1>
- Centro Nacional de Información. (2026). Estadística nacional del número de atención de llamadas de emergencia 9-1-1: enero a junio de 2026 [Conjunto de datos abiertos]. Secretariado Ejecutivo del Sistema Nacional de Seguridad Pública. <https://www.gob.mx/911/documentos/datos-abiertos-de-la-estadistica-nacional-del-numero-de-atencion-de-llamadas-de-emergencia-9-1-1>
- Centro Nacional de Prevención de Desastres [Cenapred]. (2024). Impacto socioeconómico de los principales desastres ocurridos en México: resumen ejecutivo 2023. Secretaría de Seguridad y Protección Ciudadana. <https://www.cenapred.gob.mx/es/Publicaciones/archivos/504-RESUMENEJECUTIVOIMPACTO2023.PDF>
- Chawla, N. V., Bowyer, K. W., Hall, L. O., y Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321-357. <https://doi.org/10.1613/jair.953>
- Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1), 37-46. <https://doi.org/10.1177/001316446002000104>

- Cortes, C., y Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273-297.
<https://doi.org/10.1007/BF00994018>
- Daugherty, P. R., y Wilson, H. J. (2018). *Human + machine: Reimagining work in the age of AI*. Harvard Business Review Press.
- Devlin, J., Chang, M.-W., Lee, K., y Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of NAACL-HLT 2019*, 4171-4186. <https://doi.org/10.18653/v1/N19-1423>
- Franco Cantos, J. H. (2024). Identificación automática de tweets de emergencia en la red social «X»: caso de estudio en Ecuador [Tesis de maestría, Pontificia Universidad Católica del Ecuador]. Repositorio institucional PUCE.
<https://repositorio.puce.edu.ec/items/17173477-6e8e-49ee-b041-3289294c5e3d>
- Guo, C., Pleiss, G., Sun, Y., y Weinberger, K. Q. (2017). On calibration of modern neural networks. *Proceedings of the 34th International Conference on Machine Learning*, 70, 1321-1330. <https://proceedings.mlr.press/v70/guo17a.html>
- Howard, J., y Ruder, S. (2018). Universal language model fine-tuning for text classification. *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics*, 328-339. <https://doi.org/10.18653/v1/P18-1031>
- Imran, M., Castillo, C., Diaz, F., y Vieweg, S. (2015). Processing social media messages in mass emergency: A survey. *ACM Computing Surveys*, 47(4), artículo 67. <https://doi.org/10.1145/2771588>
- Japkowicz, N., y Stephen, S. (2002). The class imbalance problem: A systematic study. *Intelligent Data Analysis*, 6(5), 429-449. <https://doi.org/10.3233/IDA-2002-6504>
- Joachims, T. (1998). Text categorization with support vector machines: Learning with many relevant features. *Proceedings of the 10th European Conference on Machine Learning*, 137-142. <https://doi.org/10.1007/BFb0026683>
- Kudo, T., y Richardson, J. (2018). SentencePiece: A simple and language independent subword tokenizer and detokenizer for neural text processing. *Proceedings of EMNLP 2018: System Demonstrations*, 66-71. <https://doi.org/10.18653/v1/D18-2012>

- Landis, J. R., y Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, 33(1), 159-174. <https://doi.org/10.2307/2529310>
- Manning, C. D., Raghavan, P., y Schütze, H. (2008). *Introduction to information retrieval*. Cambridge University Press.
- Nguyen, D. T., Al-Mannai, K., Joty, S., Sajjad, H., Imran, M., y Mitra, P. (2016). Rapid classification of crisis-related data on social networks using convolutional neural networks [Preprint]. *arXiv*. <https://arxiv.org/abs/1608.03902>
- Olteanu, A., Castillo, C., Diaz, F., y Vieweg, S. (2014). CrisisLex: A lexicon for collecting and filtering microblogged communications in crises. *Proceedings of the International AAAI Conference on Web and Social Media*, 8, 376-385. <https://ojs.aaai.org/index.php/ICWSM/article/view/14538>
- Paltin, D., Mejía, J., Orellana, M., y Zambrano-Martínez, J. (2025). Modelado semántico de emergencias del ECU 911 con NLP y ontologías. *Revista Tecnológica ESPOL*, 37(E1), 112-125. <https://doi.org/10.37815/rte.v37nE1.1351>
- Salton, G., y Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5), 513-523. [https://doi.org/10.1016/0306-4573\(88\)90021-0](https://doi.org/10.1016/0306-4573(88)90021-0)
- Sennrich, R., Haddow, B., y Birch, A. (2016). Neural machine translation of rare words with subword units. *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics*, 1715-1725. <https://doi.org/10.18653/v1/P16-1162>
- Sokolova, M., y Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4), 427-437. <https://doi.org/10.1016/j.ipm.2009.03.002>
- Valdés-Rodríguez, O. A. (2025). Declaratorias de desastre y su afectación en los cultivos de temporal más valiosos de Veracruz. *Ecosistemas y Recursos Agropecuarios*, 12(1). <https://doi.org/10.19136/era.a12n1.4015>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., y Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30, 5998-6008. <https://papers.nips.cc/paper/7181-attention-is-all-you-need>

Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., Rault, T., Louf, R., Funtowicz, M., Davison, J., Shleifer, S., von Platen, P., Ma, C., Jernite, Y., Plu, J., Xu, C., Le Scao, T., Gugger, S., ... Rush, A. M. (2020). Transformers: State-of-the-art natural language processing. Proceedings of EMNLP 2020: System Demonstrations, 38-45. <https://doi.org/10.18653/v1/2020.emnlp-demos.6>

Anexo A. Instrumento de empatía y resultados de la encuesta ciudadana

Como parte de la etapa de empatía descrita en el apartado 3.1 se aplicó una encuesta ciudadana anónima mediante un formulario en línea, difundido entre personas que hubieran vivido o presenciado una emergencia. El instrumento no recoge nombres, teléfonos ni direcciones, y se respondió con fines exclusivamente académicos. Se recibieron 42 respuestas. Este anexo reproduce el cuestionario, los resultados agregados y una selección de respuestas textuales anonimizadas.

A.1 PREGUNTAS DEL INSTRUMENTO

1. ¿Has vivido o presenciado una emergencia en tu localidad? (opción única)
2. ¿Qué tipo de emergencia? (casillas: inundación, deslave, incendio, caída de poste o cable, persona en riesgo, otro)
3. ¿Reportaste o intentaste reportar la emergencia? (opción única)
4. Si reportaste, ¿por qué medio? (casillas: 9-1-1, redes sociales, mensajería instantánea, en persona, no reporté, otro)
5. ¿Qué fue lo más difícil o frustrante al pedir o dar aviso de ayuda? (texto libre)
6. ¿Supiste si tu reporte fue recibido o atendido? (opción única)
7. ¿Qué tan seguro o segura estabas de que la ayuda llegaría a tiempo? (escala de 1 a 5)
8. ¿Qué te habría gustado que pasara con tu reporte? (texto libre)
9. Si pudieras pedir una sola cosa a un sistema que recibe estos reportes, ¿cuál sería? (texto libre)

A.2 RESULTADOS AGREGADOS

La tabla 9 presenta los tipos de emergencia mencionados por las personas encuestadas. Al tratarse de una pregunta de opción múltiple, la suma de menciones excede el número de respuestas del cuestionario.

Tabla 9. Tipos de emergencia mencionados por las personas encuestadas.

Tipo de emergencia	Menciones
Inundación	17

Caída de poste o cable	17
Otro	11
Incendio	10
Persona en riesgo	10
Deslave	3

Fuente: Elaboración propia con las respuestas del formulario (pregunta de opción múltiple, n = 42).

La tabla 10 reúne los indicadores principales del instrumento, a los que remite el apartado 3.1. Las proporciones se calculan sobre el total de 42 respuestas, salvo en la escala de confianza, donde se indican las respuestas válidas. Los porcentajes se redondean a la unidad.

Tabla 10. *Indicadores principales de la encuesta ciudadana (n = 42).*

Indicador	Resultado
Respuestas recogidas	42
Han vivido o presenciado una emergencia	83 % (35 de 42)
Reportaron / lo intentaron sin lograrlo / no reportaron	50 % / 17 % / 33 %
Principal canal de reporte	Llamada al 9-1-1 (22 menciones); uso marginal de medios digitales
No supieron si su reporte fue atendido	8 personas
Confianza en que la ayuda llegaría a tiempo (escala 1 a 5)	Media de 2.3; el 64 % la califica con 1 o 2
Emergencias más mencionadas	Inundación (17) y caída de poste o cable (17)

Fuente: Elaboración propia con las respuestas del formulario aplicado.

En cuanto a la confianza en que la ayuda llegaría a tiempo, medida en una escala de 1 —nada seguro— a 5 —totalmente seguro—, se obtuvieron 36 respuestas válidas con una media de 2.3. El 64 % de las personas la calificó con 1 o 2, y solo el 17 % con 4 o 5. Este resultado es el

que se interpreta en el apartado 3.1 como evidencia de la baja confianza ciudadana en la respuesta institucional.

A.3 VOCES DE LA CIUDADANÍA

Las respuestas de texto libre se transcriben literalmente y sin datos identificatorios. Sobre lo más difícil o frustrante al pedir ayuda, las personas encuestadas señalaron:

- «El tiempo de respuesta, la demora para la atención.»
- «No contestaban las llamadas.»
- «La lentitud con la que atienden y piden datos.»
- «La falta de empatía y la cantidad de preguntas aún en medio de la emergencia.»
- «Me dijeron que como aún no había nadie en riesgo, atenderían otras prioridades... fue súper frustrante.»

Sobre lo que les habría gustado que ocurriera con su reporte y lo que pedirían a un sistema que los recibe, las respuestas fueron:

- «Que me indicara si mi reporte tiene prioridad o en qué estatus está.»
- «Monitoreo de la cuadrilla asignada a la resolución del incidente.»
- «Trazabilidad del estatus del reporte; por ejemplo, si pedí una ambulancia, poder ver por dónde viene.»
- «Que tengan otros medios de comunicación donde no se sature rápido para comunicarse.»
- «Aviso a las autoridades y atención por nivel de emergencia.»

La última cita resulta especialmente pertinente para este trabajo, porque expresa en palabras de la ciudadanía la función que el sistema propuesto cumple: que la atención se organice por nivel de emergencia. Las peticiones de trazabilidad y seguimiento, reiteradas en varias respuestas, quedan registradas como línea de trabajo futuro según se declaró al delimitar el alcance.

Anexo B. Mapa de empatía y criterio operativo de urgencia

Este anexo reúne el detalle tabulado de dos instrumentos elaborados en la etapa de desarrollo conceptual: el mapa de empatía de los dos perfiles de usuario, al que remite el apartado 3.1, y el criterio operativo con el que se asigna el nivel de urgencia a cada reporte, al que remite el apartado 3.2. Ambos se presentan aquí para no interrumpir la argumentación del cuerpo del documento.

B.1 MAPA DE EMPATÍA

Tabla 11. Mapa de empatía de los usuarios de SIREC.

Usuario	Dolores	Beneficios esperados
Operador de protección civil	Leer decenas de reportes uno por uno; riesgo de que un caso crítico quede sepultado por el orden de llegada; fatiga y decisiones bajo presión de tiempo; falta de un criterio común de urgencia	Recibir los reportes ya ordenados por prioridad; ahorrar tiempo de lectura; reducir el riesgo de omitir un caso grave; concentrar el esfuerzo en decidir y despachar
Ciudadano reportante	Esperas largas y llamadas que no se contestan, el dolor más citado; muchas preguntas en plena emergencia; criterios de prioridad poco claros; incertidumbre sobre si el reporte fue recibido; baja confianza en que la ayuda llegará a tiempo	Que un reporte con riesgo para la vida se atienda con prioridad; recibir confirmación y seguimiento del estatus; contar con un canal accesible que no dependa solo de la línea telefónica saturada

Fuente: Elaboración propia a partir del análisis del proceso, las visitas presenciales y las respuestas del formulario ciudadano.

B.2 CRITERIO OPERATIVO DE URGENCIA

Tabla 12. Criterio operativo de asignación del nivel de urgencia.

Nivel	Definición operativa	Ejemplos de frontera
Alta	Riesgo inminente para la vida o la	Persona atrapada en una vivienda

	integridad física de una o más personas	inundada; incendio con gente en el interior; persona herida en la vía pública; cable energizado caído sobre una persona
Media	Afectación relevante de bienes o servicios, o situación que puede escalar, sin peligro inmediato para las personas	Vehículo volcado sin personas atrapadas; vivienda con daño estructural sin ocupantes en riesgo; poste caído que obstruye la circulación
Baja	Incidente menor o aviso de carácter informativo, sin afectación clara a personas	Encharcamiento en la vía pública; cable colgando sin contacto; acumulación de basura tras la lluvia

Fuente: Elaboración propia; el criterio completo, con más ejemplos de frontera, se documenta en la guía de etiquetado del proyecto.

El principio rector que acompaña a este criterio, aplicado por los anotadores ante la duda entre dos niveles, consiste en asignar el nivel superior cuando existen personas expuestas. Esta regla asimétrica es deliberada y coherente con el tratamiento que el apartado 3.7 da a los falsos negativos en las clases críticas.